

• 中枢神经影像学 •

人在回路深度学习垂体分割模型的建立

冷淥清,花蕊,石峰,陈明,吴玉桥,朱珠

【摘要】 目的:采用深度学习方法,通过人在回路的方式进行迭代式标注-训练,建立垂体分割模型,实现垂体体积人工智能(AI)测量。**方法:**将 1285 例颅脑 3D T₁WI 图像按 5~15 岁、16~25 岁、26~50 岁、51~70 岁年龄段分组,每个年龄组随机选择 80 例,分成 4 批次进行试验。初始每组选择 3 例图像进行人工预标注神经垂体和腺垂体,输入计算机进行学习,获取初始模型。应用模型对一批数据进行分割,获得分割后的神经垂体、腺垂体与垂体总体积数据,将分割结果进行人工校准,获得校准后相对应的体积数据作为金标准。用前一组校准后的分割图像进行计算机迭代式学习优化模型,再用优化后模型对新一组图像分割与校准,重复上述过程,最终将校准前后差异没有统计学意义的差异数据认定深度学习建模成功。数据采用配对 *t* 检验、Dice 和 Spearman 相关性分析进行统计。**结果:**从第 2 批次开始,除 5~15 岁年龄段外,其它年龄段神经垂体体积在校准前后的差异没有统计学意义,腺垂体与垂体总体积的差异有统计学意义($P<0.05$)。第 4 批次,各年龄段神经垂体、腺垂体与垂体总体积在校准前后的差异均无统计学意义($P=0.137\sim0.928$),Dice 值大于 0.941, Spearman 相关系数大于 0.969。**结论:**通过迭代式训练进行深度学习建模可构建垂体分割模型,实现垂体体积 AI 自动测量。

【关键词】 垂体;深度学习;人在回路;自动分割;迭代式训练

【中图分类号】 R445.2;R584;R-05 **【文献标识码】** A **【文章编号】** 1000-0313(2024)03-0330-05

DOI:10.13609/j.cnki.1000-0313.2024.03.005

开放科学(资源服务)标识码(OSID):



Establishment of a deep learning pituitary segmentation model with human in the loop strategy LENG Lu-qing, HUA Rui, SHI Feng, et al. Chengdu Yinghe Medical Imaging Diagnosis Center, Chengdu 610058, China

【Abstract】 Objective: Using the deep learning method, iterative labeling training was carried out through the human-in-the-loop method to establish a pituitary segmentation model and realize the artificial intelligence (AI) measurement of pituitary volume. **Methods:** 1285 cases of brain 3D T₁WI images were divided into groups of 5~15 years old, 16~25 years old, 26~50 years old, and 51~70 years old. 80 subjects of each age group were randomly selected and divided into 4 batches for the test. Initially, 3 subjects of each group were selected for radiologist pre-labeling of neurohypophysis and adenohypophysis, and input to the computer for learning to obtain the initial model. This model was then used to segment a batch of data to obtain the labeled neurohypophysis, adenohypophysis, and total pituitary volume. The segmentation results were manually calibrated by a radiologist, and the corresponding volume data after calibration was obtained as the gold standard. The computer iteratively learned to optimize the model with the previous set of calibrated segmentation images, and then used the optimized model to segment and calibrate a new set of images. The above process was repeated, and finally the deep learning modeling was identified successful if the difference between the data before and after calibration was not statistically significant ($P>0.05$). Data were analyzed by paired *t*-test, Dice, and Spearman correlation analysis. **Results:** From the second batch, there was no statistically significant difference in neurohypophysis volume before and after calibration except for the 5~15 years old group, while the difference between adenohypophysis and total pituitary volume was statistically significant ($P<0.05$). In the fourth batch, the neurohypophysis, adenohypophysis, and total pituitary volume were more consistent before and after calibration across all age groups ($P=0.137\sim0.928$), the

作者单位:610058 成都,成都影和医学影像诊断中心(冷淥清、吴玉桥、朱珠);200030 上海,上海联影智能医疗科技有限公司(花蕊、石峰);629099 四川,四川省遂宁市中心医院放射科(陈明)

作者简介:冷淥清(1968—),男,四川眉山人,硕士研究生,副主任医师,主要从事功能磁共振与结构磁共振研究。

基金项目:四川省医学科研课题计划项目(S21103)

Dice value was greater than 0.941, and the Spearman correlation was greater than 0.969. **Conclusion:** Deep learning modeling through iterative training can build a human pituitary segmentation model and realize AI automatic measurement of pituitary volume.

【Key words】 Pituitary; Deep learning; Human in the loop; Automatic segmentation; Iterative training

垂体作为人体重要的内分泌腺,与其相关病变的诊断与治疗一直受到临床关注,最常见的包括矮小症、肥胖症、垂体增生以及垂体微腺瘤等,特别是矮小症和肥胖症患者垂体大小检查已成为常规。实际工作中都采用高度值来衡量垂体大小,因大部分垂体形态欠规则,不同的测量点可能造成值的差异性,如果用体积替代高度衡量垂体大小,将减少相应的问题并提高垂体病变检出的敏感性。目前部分设备或软件可以进行体积测量,需人工逐层勾画后计算,操作繁琐,本研究拟通过计算机深度学习,探讨人工智能(artificial intelligence, AI)用于垂体体积自动测量的可行性。

人在回路(human in the loop)机器学习方式是通过人与机器学习过程进行交互,此方法不仅可以增加机器学习的准确性,还可以明显提高人工效率,是近年来 AI 研究中受到业内认可的方法,通常表现为迭代式建模和纠错^[1,2]。

材料与方法

训练数据来源于 CoRR(Consortium for Reliability and Reproducibility)公开数据库中 5~70 岁年龄段颅脑 3D T₁WI 图像 1285 例。纳入标准:垂体高度 3~10 mm,腺垂体与神经垂体显示清晰。按照 5~15 岁、16~25 岁、26~50 岁、51~70 岁年龄段分成 4 组,每组随机选择 80 例,分 4 批次进行试验,单次每个年龄组随机选择 20 例,不合格样本剔除后参照随机原则补足。

标注采用 Slicer 4.11 版本软件,图像格式为 NIFTI,神经垂体和腺垂体独立标注,标注标准如下:①神经垂体的标注区域为垂体后叶区高 T₁ 信号区(图 1),除神经垂体外,垂体窝内非低信号区均标为腺垂体,低信号灶不在标注范围(图 2)。②垂体标注采用横轴面、矢状面和冠状面三个方位共同标注,其中矢状面侧重上下界线,横轴面和冠状面侧重左右界线,在矢状面图像上左右界线难判定时以横轴面或冠状面为准,而横轴面和冠状面上下界线难判定时以矢状面为准(图 3)。③标注过程中,海绵窦血管、鞍区骨质、鞍旁间隙以及场强因素导致的垂体信号不均匀可能造成干扰,在人工校准时需注意修正(图 4~6)。④部分样本可能存在侧壁增厚且与腺体分界不清,标注时参照邻近侧壁软组织信号厚度进行剔除(图 7)。垂体分割模型

使用级联的 VB-Net 网络进行训练,该网络是 V-Net^[3]的变体,在 V-Net 网络框架基础上加入瓶颈层,减少网络参数数量,降低显存。第一级 VB-Net 网络对垂体进行粗分割,定位垂体位置;第二级 VB-Net 网络基于垂体分割结果切块进行精细分割,把垂体分割成神经垂体和腺垂体两部分(图 8)。

垂体分割模型采用迭代式标注-训练的方法获得,包含以下步骤:①初始每组选择 3 例图像进行人工标注神经垂体和腺垂体,将人工标注后图像作为训练集进行模型训练,直至模型收敛,可以初步完成垂体分割,获取初始模型。如果无法完成初始模型建立,追加人工标注分割病例,直至计算机获得初始模型。②应用初始模型对首批 80 例图像进行分割,获得分割后的神经垂体、腺垂体与垂体总体积数据,将分割结果进行人工校准,获得校准后相对应的体积数据作为金标准。③使用配对样本 *t* 检验对获得的数据进行统计分析,如果 AI 测量值与人工测量值任意一个年龄组差异有统计学意义,则把本次人工校准后的垂体图像与分割图像加入训练集,对上一次模型进行迭代优化。利用优化后的新模型继续进行下一批次图像 AI 分割与人工校准,获得新一组测试数据。④重复进行步骤③,直到 AI 测量值和人工测量值在所有年龄段差值均没有统计学意义为止。

进行统计分析的垂体体积数据包括神经垂体、腺垂体和总垂体 3 个值,采用 AI 识别自动测量和人工校准分别获得 AI 测量值与人工测量值两组数据,应用 Python 和 SPSS 软件对两组数据进行配对 *t* 检验、Dice 计算和 Spearman 相关性分析,*t* 检验以 $P > 0.05$ 为两组数据差异没有统计学意义。

结 果

经过初始 12 例人工标注后病例的训练,计算机能进行垂体识别与简单分割,初始模型建立成功。

经过 4 批次 AI 标注与再学习、人工校准,第 4 批次各年龄段神经垂体、腺垂体以及总垂体体积校正前后数据差值没有统计学意义,*t* 值为 0.137~0.928。各批次 *t* 检验结果见表 1。

第 4 批次各年龄段人工校准前后,最小 Dice 值 0.941 为 16~25 岁年龄段神经垂体数据,最大值 0.989 为 25~50 岁年龄段垂体总体积数据(表 2)。同组数




图 1 a)垂体矢状面 T_1 WI 示腺垂体为等信号,神经垂体为高信号;b)标注图像,将等信号腺垂体区域标注为浅绿色,将高信号神经垂体区域标注为浅黄色。

图 2 a)垂体横轴面 T_1 WI 示腺垂体区

见等低混杂信号;b)标注图像,将腺垂体内等信号标注为浅绿色,低信号区不标注。图 3 a)冠状面 T_1 WI 示腺垂体左侧缘浅绿色标注点(箭)超出腺垂体区域;b)垂体矢状面 T_1 WI 图像,箭头所示区域与 a 图一致,无法判断是否标注异常。图 4 垂体横轴面 T_1 WI 图像。a)双侧迂曲颈内动脉(箭)推移腺垂体;b)AI 测算的腺垂体区域并标注为浅绿色,AI 误将部分右侧动脉血管标注为腺垂体(箭);c)人工校准后腺垂体范围,清除了 AI 误标的部分右侧动脉血管。图 5 a)垂体冠状面 T_1 WI 图像示鞍底骨质稍低信号带(箭)与上方等信号腺垂体结构分界清楚;b)垂体矢状面 T_1 WI 图像示鞍底骨质与腺垂体之间分界欠清。图 6 a)垂体冠状面 T_1 WI 图像示鞍底左侧高信号(箭)无法判断是否为神经垂体;b)垂体矢状面 T_1 WI 图像示鞍底高信号区(箭)与神经垂体存在明显界线。图 7 a)垂体冠状面 T_1 WI 图像示左侧鞍旁侧壁增厚(箭),与腺垂体分界不清;b)为同层面图像示标注腺垂体等信号区减标范围(箭)与侧壁厚度相似。




图 8 级联的 VB-Net 网络框架。

据进行 Spearman 相关性分析,校准前后腺垂体、神经垂体及垂体总体积相关系数分别为 0.969、0.981 和 0.984(表 3)。

经过电脑反复 3 批次学习与人工校准,第 4 批次 AI 标注的各年龄段神经垂体、腺垂体与垂体总体积三组数据均与人工校准数据的差异没有统计学意义, Dice 值为 0.941~0.989, Spearman 相关系数大于 0.969, 标志着 AI 深度学习的垂体分割模型建立成功。

讨 论

人工智能在医学影像方面的应用近年来不断增多,相关领域也成为医疗机构研发的重要方向^[4,5]。垂体人工智能与数字化领域相关的研究,主要集中在鞍区病变的手术方案设计、AI 辅助定性及放疗定位,方法上以影像学多模态结合计算机不同算法建模、动态不确定因果图以及相关放疗定位软件^[6-8]。国内有

表 1 不同年龄段各次人工校准前后垂体体积 *t* 检验结果

批次/年龄组	腺垂体		神经垂体		总垂体	
	<i>t</i> 值	<i>P</i> 值	<i>t</i> 值	<i>P</i> 值	<i>t</i> 值	<i>P</i> 值
1						
5~15 岁	-6.253	<0.001	4.547	<0.001	-1.568	0.136
16~25 岁	-1.372	0.186	1.571	0.133	-0.632	0.535
26~50 岁	-6.283	<0.001	2.918	0.011	-3.932	0.001
51~70 岁	2.671	0.016	5.644	<0.001	4.899	<0.001
2						
5~15 岁	-3.848	0.001	-0.824	0.420	-3.576	0.002
16~25 岁	-5.075	<0.001	-0.902	0.380	-3.442	0.003
26~50 岁	-4.776	<0.001	1.909	0.071	-4.824	<0.001
51~70 岁	-5.760	<0.001	-0.453	0.655	-3.424	0.003
3						
5~15 岁	-2.969	0.008	2.500	0.022	-2.336	0.031
16~25 岁	-4.767	<0.001	-1.288	0.212	-4.767	<0.001
26~50 岁	-2.954	0.008	0.032	0.974	-2.341	0.030
51~70 岁	-4.040	<0.001	0.976	0.340	-3.962	<0.001
4						
5~15 岁	0.132	0.896	-0.310	0.759	0.091	0.928
16~25 岁	0.748	0.463	-0.455	0.653	0.400	0.693
26~50 岁	0.827	0.418	-1.012	0.323	-0.867	0.396
51~70 岁	1.310	0.205	0.887	0.385	1.551	0.137

表 2 第 4 批次各年龄段人工校准前后垂体各区域分割对比 Dice 值

年龄组	5~15 岁	16~25 岁	26~50 岁	51~70 岁
腺垂体	0.973±0.05	0.973±0.04	0.982±0.03	0.962±0.05
神经垂体	0.971±0.05	0.941±0.20	0.967±0.08	0.987±0.04
总垂体	0.976±0.04	0.976±0.05	0.989±0.01	0.970±0.04

表 3 第 4 批次人工校准前后数据 Spearman 相关性分析

测量数据/统计值	校准前 腺垂体 体积	校准后 腺垂体 体积	校准前 神经垂体 体积	校准后 神经垂体 体积	校准前 垂体体积	校准后 垂体体积
校准前腺垂体体积						
相关系数	1.000	0.969	-0.007	-0.002	0.962	0.949
<i>P</i>		<0.001	0.948	0.989	<0.001	<0.001
校准后腺垂体体积						
相关系数	0.969	1.000	-0.057	-0.058	0.918	0.936
<i>P</i>	<0.001		0.618	0.609	<0.001	<0.001
校准前神经垂体体积						
相关系数	-0.007	-0.057	1.000	0.981	0.217	0.200
<i>P</i>	0.948	0.618		<0.001	0.053	0.076
校准后神经垂体体积						
相关系数	-0.002	-0.058	0.981	1.000	0.219	0.205
<i>P</i>	0.989	0.609	<0.001		0.050	0.069
校准前垂体体积						
相关系数	0.962	0.918	0.217	0.219	1.000	0.984
<i>P</i>	<0.001	<0.001	0.053	0.050		<0.001
校准后垂体体积						
相关系数	0.949	0.936	0.200	0.205	0.984	1.000
<i>P</i>	<0.001	<0.001	0.076	0.069	<0.001	

人对垂体疾病建立数据库,辅助疾病诊断与治疗^[9]。针对垂体区域无明显病变的研究相对较少,主要研究范围为激素相关病变垂体大小情况分析,如矮小症、肥胖症等,类似研究中,衡量垂体变化的参数多数是采用垂体高度值变化,只有少数研究基于 3D 软件人工勾画进行垂体体积半自动定量分析^[10,11]。

针对形态规则的垂体径线测量,可重复性尚好,如果垂体形态欠规则,测量值的重复性会相应变差,垂体体积与垂体形态无关,因此采用体积来进行垂体的大小评估,将有效解决重复性差的问题。以球体体积计算为例, $V=(4/3)\pi r^3$ (V 体积, r 球体半球),当直径从 4 mm 增大到 5 mm 时,增大了约 25%,但体积将从 33.5 mm³ 增加到 65.4 mm³,增大约 95%,体积的变化是长度值变化的 4 倍,因此,体积在反映物体变化上比径线更敏感。随着 3D T₁WI 高分辨序列在 1.5T 以上设备的普及,若能实现 AI 垂体体积自动标识,将有利于垂体定期复查并早期发现异常变化,达到早期发现病变的目的。区别于实物模型,AI 垂体分割模型是指计算机获得的一种算法,是经过反复学习后计算机成功区分指定区域的能力,在本研究中表现为对神经垂体和腺垂体的自动识别。

研究所用图像为公共数据库 3D T₁WI 颅脑矢状面图,层厚 1 mm,无间隔扫描,图像设备无限制。实验中,将垂体窝内等 T₁ 组织认定为腺垂体,类似 Rathke 囊肿低信号灶被排除在腺垂体范围外,垂体后缘高 T₁ 信号认定为神经垂体,实验只对比两种方法对认定的腺垂体和神经垂体区域体积测量值,不涉及疾病诊断与正常值测量。

磁共振扫描中,呼吸运动、蝶窦空气、海绵窦区血管以及骨质常干扰腺垂体信号,其中以场强不均匀所致的腺垂体高信号伪影较多见,主要表现在腺垂体外周区域,校准时应注意与神经垂体区分开,将其归入腺垂体,在定位上以神经垂体解剖位置靠后作为参考依据,需横轴面、冠状面、矢状面多方位反复校正。图 7 所示侧壁增厚,在标注过程中不少见,产生侧壁增厚的原因可能与局部蝶窦骨质信号或海绵窦信号有关,标注中如无法与邻近腺垂体分界开,参考垂体外组织厚度进行减少标记,这样可以防止腺垂体体积假性增多。

本研究中 4 个年龄段参考垂体发育时段设计,通过增加时段与总数据共同对比的差异性,增加了全数据对比差异没有统计学意义的难度,进而提高了 AI 模型标准。

目前,垂体体积的测量没有明确的金标准,临床相关研究均以 3D 软件进行人工标记后计算的数据作为金标准^[10,11]。评估 AI 分割与金标准数据比较常用相似度来分析,采用 Dice 值^[7,12,13],该值越接近 1,表示

待评估的分割值与金标准分割之间相似度越高,本研究第 4 批次数据 Dice 值达 0.941 以上,结合同组数据校准前后腺垂体、神经垂体与垂体总体积的相关系数大于 0.969,说明 AI 识别的相似度已接近人工标准。

本研究用 12 例图像进行计算机训练建立初始模型后,采用迭代学习与纠错方式反复优化,经过 3 批次学习,第 4 批次数据即达到校准前后数据差异没有统计学意义,且 Dice 值大于 0.941,初步认为 AI 垂体分割建模成功。AI 垂体分割模型建立后,尚需要不同单位不同机型的更多数据导入进行迭代学习与模型优化,最终训练成能识别不同设备垂体分区的成熟模型,实现垂体体积 AI 自动精准测量。

参考文献:

- [1] Zhang J, Fiers P, Witte KA, et al. Human-in-the-loop optimization of exoskeleton assistance during walking[J]. *Science*, 2017, 356: 1280-1284.
- [2] Shan F, Gao YZ, Wang J, et al. Abnormal lung quantification in chest CT images of COVID-19 patients with deep learning and its application to severity prediction[J]. *Med Phys*, 2021, 48(4): 1633-1645.
- [3] Milletari F, Navab N, Ahmadi S, et al. V-Net: fully convolutional neural networks for volumetric medical image segmentation[C]//2016 Fourth International Conference on 3D Vision, 2016: 565-571.
- [4] 黄栋有, 高先聪, 尤传文. 基于乳腺 X 线图像纹理特征建立机器学习模型在鉴别良恶性乳腺肿块中的价值[J]. *放射学实践*, 2021, 36(4): 480-483.
- [5] 尹伟, 王敏杰, 徐瑞敏, 等. 基于人工智能的辅助运动校正算法对 CCTA 图像质量的影响[J]. *放射学实践*, 2022, 37(8): 1035-1041.
- [6] Liu Y, Liu X, Hong X, et al. Prediction of recurrence after transphenoidal surgery for Cushing's disease: the use of machine learning algorithms[J]. *Euroendocrinology*, 2019, 108(3): 201-210.
- [7] Wang H, Zhang W, Li S, et al. Development and evaluation of deep learning-based automated segmentation of pituitary adenoma in clinical task[J]. *Clin Endocrinol Metab*, 2021, 106(9): 2535-2546.
- [8] Kim M, Kim HS, Park JE, et al. Thin-slice pituitary MRI with deep learning-based reconstruction for preoperative prediction of cavernous sinus invasion by pituitary adenoma: a prospective study[J]. *Am J Neuroradiol*, 2022, 43(2): 280-285.
- [9] 王任直, 冯铭, 范阳华. 完善垂体疾病数据库建设开展高质量临床研究[J]. *协和医学杂志*, 2020, 11(3): 339-342.
- [10] Fehrenbach U, Jadan A, Auer TA, et al. Obesity and pituitary gland volume—a correlation study using three-dimensional magnetic resonance imaging[J]. *Neuroradiol J*, 2020, 33(5): 400-409.
- [11] Rass V, Schoenherr E, Iani BA, et al. Subarachnoid hemorrhage is followed by pituitary gland volume loss: a volumetric MRI observational study[J]. *Neurocrit Care*, 2020, 32(2): 492-501.
- [12] Taha AA, Hanbury A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool[J]. *BMC Med Imaging*, 2015, 15(1): 29-56.
- [13] 张晓宇, 王彬, 安卫超, 等. 基于融合损失函数的 3D U-Net++ 脑胶质瘤分割网络[J]. *计算机科学*, 2021, 48(9): 188-193.

(收稿日期: 2022-12-19 修回日期: 2023-04-25)